

Control de tráfico agent-based

Control por aprendizaje por refuerzo para corredores en Puebla

Integrantes: Sarah, Bryan Violante Arriaga, Helen Alondra Pillado Hernández

Asesor: Dr. Saúl Pomares Hernández

Repositorio: <https://github.com/zxxz456/electrohack2026>

Resumen

Los semáforos de Puebla operan casi todos con ciclos fijos: no responden a la demanda real, provocan paradas y arranques innecesarios y dependen de la red eléctrica. Proponemos un corredor de intersecciones semaforizadas alrededor de Ciudad Universitaria (BUAP) en el que cada semáforo es un nodo autónomo alimentado con energía solar y controlado por un agente de aprendizaje por refuerzo. Cada agente toma en cuenta el estado de sus intersecciones vecinas, recibido por radio LoRa en un mensaje de 5 bytes, y de esa anticipación local emerge la coordinación del corredor sin un controlador central. El sistema optimiza a la vez el flujo vehicular, el consumo de energía (kWh), consumo de energía (autos eléctricos), las emisiones del corredor, y el tiempo de cruce peatonal. Todo se evalúa en simulación con SUMO sobre la red vial real, completada con el inventario municipal de semáforos, y contra la operación actual de tiempo fijo (baseline, no se construye hardware).

1. Contexto y problema

Un semáforo de tiempo fijo cambia a verde según un plan calculado para una demanda promedio. Cuando la demanda cambia (lo que ocurre casi todo el tiempo), el plan deja de ajustarse, hay colas en un acceso mientras el otro recibe verde vacío, y los vehículos se detienen y arrancan más veces de las necesarias. Cada parada y arranque cuesta energía (kilowatt-hora en un vehículo eléctrico, combustible y emisiones en uno de combustión). Además, el semáforo depende de la energía eléctrica, una falla en el sistema eléctrico deja el cruce sin control.

2. Qué proponemos

2.1. Un agente por intersección, atento a sus vecinos

Cada cruce o intersección tiene su propio controlador, un agente de aprendizaje por refuerzo (DQN) que decide cada x segundos si extiende la fase actual o avanza a la siguiente. Además de su propio estado (colas, velocidades, fase activa), el agente recibe de cada intersección vecina:

- la longitud de cola en la aproximación del semaforo vecino que descarga hacia él;
- la fase activa del semaforo vecino y el tiempo que lleva en ella;
- la *intención* del semaforo vecino: la fase que piensa activar a continuación.

Con eso el agente puede anticiparse: “el semaforo de la intersección Y va a dejar pasar X autos que llegan en aprox. Z segundos, conviene estar en verde”. La *onda* verde no se programa desde un centro de control; emerge de decisiones locales.

Hay tres niveles posibles de coordinación. Este proyecto implementara hasta el segundo:

1. Compartir colas: solo la cola del vecino entra a la observación.
2. **Compartir colas, fase e intención** (objetivo del proyecto).
3. Negociación explícita con un crítico centralizado (MAPPO, QMIX). Queda como trabajo futuro por el riesgo de no converger a tiempo.

2.2. Comunicación mínima entre nodos

En el nodo real la información viajaría por radio LoRa (SX1276), con alcance de kilómetros y consumo despreciable. El mensaje cabe en 5 bytes (tabla 1); a un mensaje por paso de decisión, cada nodo transmite 1 byte por segundo por vecino. En la simulación la observación de vecinos se construye codificando y decodificando exactamente ese mensaje, así el agente ve los mismos valores cuantizados que llevaría el radio, con un paso de retraso.

Tabla 1: Mensaje entre intersecciones vecinas.

Campo	Codificación	Bits
Identificador del emisor	entero de 8 bits	8
Número de secuencia	entero de 8 bits	8
Cola hacia el receptor (vehículos, tope 255)	entero de 8 bits	8
Fase activa	índice de 2 bits	2
Fase prevista (intención)	índice de 2 bits	2
Tiempo en la fase (s, tope 63)	6 bits	6
Demanda peatonal	1 bit	1
Reservado	–	5
Total		40 bits = 5 bytes

2.3. Nodo autónomo alimentado con energía solar

Cada intersección se concibe como un nodo sin dependencia eléctrica, panel fotovoltaico, controlador de carga MPPT, batería LiFePO4, sensado por radar de onda continua (sin obra en el pavimento) y el enlace LoRa (figura 1). El nodo sigue operando durante un apagón, y si se pierde el enlace con los vecinos, cada intersección sigue funcionando con su política local.




Figura 1: Arquitectura propuesta del nodo de una intersección. En naranja, el flujo de energía; en gris, información. El mensaje con cada vecino mide 5 bytes.

IMPORTANTE: En el proyecto no se piensa implementar HW, solo se realizara la simulacion.

2.4. Seguridad fuera del agente

Las restricciones de seguridad vial no se aprenden, se imponen antes de que el agente elija, enmascarando las acciones ilegales. Una acción que las violaría nunca llegaría al semáforo, así que el agente no podría aprender a romperlas.

Tabla 2: Restricciones duras aplicadas a todos los controladores.

Restricción	Valor
Verde mínimo vehicular	10 s
Ámbar	3 s, fijo
Todo rojo	2 s
Verde máximo	60 s (evita que un acceso espere indefinidamente)
Verde peatonal mínimo	tiempo de arranque + ancho del cruce / 1.0 m/s

2.5. Qué optimizaría el agente

La recompensa combina los tres objetivos y castiga el cambio frecuente de fase, un vicio conocido de los agentes de semáforos:

$$r = -(\alpha W_{\text{veh}} + \beta E_{\text{corredor}} + \gamma C_{\text{fase}} + \delta W_{\text{peat}}), \quad (1)$$

donde W_{veh} es la espera vehicular normalizada, E_{corredor} la energía consumida por los vehículos del corredor (modelos HBEFA de combustión y modelo eléctrico de SUMO), C_{fase} los cambios de fase y W_{peat} la espera peatonal. Los pesos se reportan como estudio de ablación. Para no desestabilizar el entrenamiento, primero se entrenaría solo con α y γ , y luego se agregarían β y δ .

3. Alcance

Tabla 3: Qué entra y qué no entra en el proyecto.

Dentro del alcance	Fuera del alcance, y por qué
Simulación en SUMO de la red real alrededor de CU BUAP, con sus semáforos reales.	Construcción de hardware: solo dimensionamiento y cotizaciones reales.
Cinco controladores comparados (sección 5) en cuatro escenarios.	Un modelo de lenguaje como controlador: un modelo de 7B consume 10–15 W sostenidos, lo mismo que el propio semáforo.
Coordinación de nivel 2: colas, fase e intención de los vecinos.	Aprendizaje multiagente con crítico centralizado (MAPPO, QMIX): trabajo futuro.
Métricas de tráfico, energía, emisiones y peatones contra tiempo fijo.	Despliegue en vía pública.
Dimensionamiento del nodo solar con irradiancia de PVGIS.	Calibración con aforos vehiculares reales, salvo que se consigan a tiempo.

4. Zona de estudio y datos usados hasta ahora

4.1. Zona

Se propone la periferia de Ciudad Universitaria de la BUAP un anillo formado por el Blvd. Valsequillo, la Av. San Claudio, la 24 Sur y el Blvd. Municipio Libre, con intersecciones semaforizadas consecutivas y flujo alto en horas pico (experiencia propia), creo que es una muestra representativa pero se pueden proponer alternativas.

El área descargada de OpenStreetMap mide 2.14×3.52 km (7.5 km²); la red simulada suma unos 262 km de calle vehicular, 2,187 cruces y 2,653 cruces peatonales (figura 2).




Figura 2: Red vial simulada y sus 40 semáforos. Los círculos azules son semáforos agregados desde el inventario municipal; los cuadros naranjas ya venían en OpenStreetMap. La red se extiende fuera del área descargada porque conserva completas las calles que cruzan el borde.

4.2. Datos

Tabla 4: Fuentes de datos del proyecto.

Fuente	Uso	Estado
OpenStreetMap [12]	Red vial: calles, carriles, sentidos, vueltas. Extracto congelado el 26/09/2026.	En uso
Inventario de Semáforos SEMOVINFRA 2021 [11]	Ubicación de los semáforos reales. 3,283 postes en la ciudad, 156 en el área.	En uso
Inventario SEMOVINFRA, tabla 2020 [11]	Comparación entre levantamientos (3,054 postes).	Guardado
Modelos de emisión y energía de SUMO [10, 9]	Consumo y emisiones por vehículo.	Integrado en SUMO
PVGIS [13]	Irradiancia para dimensionar el nodo solar.	Pendiente
Aforos vehiculares	Calibrar la demanda de hora pico.	Por conseguir

4.3. Semáforos faltantes

OpenStreetMap solo tenía 8 semáforos en la zona. El inventario municipal registra 36 intersecciones semaforizadas dentro del área. Como cada registro del inventario es un poste y no una intersección, agrupamos los postes cercanos (a 35 m o menos, o a 80 m si nombran las mismas calles) y emparejamos cada grupo con el cruce más cercano de la red, a menos de 30 m. Todas las intersecciones quedaron a menos de 11 m de su cruce. Fuera del área, en los tramos que la red conserva, solo agregamos semáforos en cruces completos: en la orilla la calle transversal suele faltar, y un semáforo ahí solo agregaría demora artificial.

Tabla 5: Semáforos de la red simulada.

	Cantidad
Intersecciones del inventario dentro del área	36
Intersecciones del inventario en la orilla, con cruce completo	1
Intersecciones del inventario en la red	37
ya presentes en OpenStreetMap	5
agregadas desde el inventario	32
con cabezas peatonales	11
Semáforos de OpenStreetMap que no están en el inventario	3
Semáforos en la red	40

Alrededor de CU hay 11 intersecciones semaforizadas: cinco sobre San Claudio (con 14 Sur, 18 Sur, la entrada a la Facultad de Derecho, 22 Sur y 24 Sur), dos sobre Municipio Libre (con 24 Sur y con Valsequillo) y cuatro sobre Valsequillo (con Universidad de Chapingo, UNAM, 63 F Oriente y 14 Sur). Son las candidatas a operar con agentes; el resto de la red sigue con tiempo fijo. Dos pares están

a menos de 120 m entre sí y probablemente convenga controlar cada par como una sola intersección; si el tiempo no alcanza, el plan es reducir el experimento a un arco de 4 o 5 intersecciones sobre San Claudio.

En caso de cambiar de punto de interés, o querer probar otras zonas, se puede realizar el mismo procedimiento para cualquier otra zona de interés

4.4. Reproducibilidad

El proyecto vive en un repositorio con el extracto de OpenStreetMap congelado, el inventario, las configuraciones y el código. Cualquier integrante reconstruye la misma red con un solo comando; la construcción termina verificando que estén todos los semáforos declarados y se detiene con error si falta alguno. Verificamos que la red se reconstruye idéntica en un directorio limpio. La figura 3 muestra la red cargada en el simulador.




Figura 3: La red alrededor de CU BUAP en la interfaz gráfica de SUMO.

5. Cómo lo vamos a evaluar

5.1. Controladores

Los agentes DQN [4] se entrenan de forma independiente, uno por intersección (*Independent Q-Learning* [5]), con Stable-Baselines3 [6] sobre un entorno Gymnasium construido a partir de sumo-rl [7] y SUMO [1]. **La comparación entre el controlador 3 y el 4 es el resultado más importante:** mismo agente y mismo código, con el bloque de vecinos encendido o apagado.

Tabla 6: Controladores comparados.

#	Controlador	Papel
1	Tiempo fijo	Línea base obligatoria: cómo operan hoy los semáforos. Planes calculados con el método de Webster [8].
2	Max-pressure [3]	Regla sin aprendizaje con garantías de estabilidad. Es el plan B si el DQN no converge a tiempo.
3	DQN sin vecinos	Mismo agente, solo con observación local. Aísla cuánto aporta la coordinación.
4	DQN con vecinos	El controlador principal.
5	Jev (TypeSafe AI)	Opcional, sujeto a acceso a la API. Decisiones tipadas con nivel de confianza; cae a max-pressure si la confianza es baja.

5.2. Métricas

Todas se reportan contra tiempo fijo, como media y dispersión sobre al menos cinco semillas de evaluación distintas de las de entrenamiento, con los mismos archivos de demanda para todos los controladores.

Tabla 7: Métricas.

Dimensión	Indicador
Tráfico	Tiempo de espera medio, paradas por vehículo, longitud de cola.
Coordinación	Paradas en el corredor completo, tiempo de viaje de extremo a extremo.
Energía	kWh consumidos en el corredor, CO ₂ evitado.
Peatones	Tiempo de espera peatonal, cruces con verde suficiente.
Económica	Costo por intersección, retorno frente a la acometida eléctrica.

5.3. Escenarios

1. Tráfico típico de hora pico.
2. Tráfico asimétrico, con un sentido dominante: donde la coordinación debería rendir más.
3. Pérdida del enlace con los vecinos: observaciones de vecinos en cero.
4. Incidente: un carril bloqueado en una intersección intermedia.

6. Qué esperamos obtener

No tenemos resultados todavía. Estas son las hipótesis que el proyecto pone a prueba; cualquiera puede resultar falsa, y en ese caso se reporta como tal.

- H1.** Max-pressure reduce la espera media frente a tiempo fijo en hora pico.
- H2.** El DQN con vecinos reduce las paradas en el corredor y el tiempo de viaje de extremo a extremo frente al DQN sin vecinos, sobre todo con tráfico asimétrico.
- H3.** Al perder el enlace, el DQN con vecinos se degrada hacia el desempeño del DQN local, sin dejar de operar.

H4. Menos paradas y arranques se traducen en menos energía y emisiones por vehículo-kilómetro en el corredor.

Entregables: la simulación reproducible, las comparaciones con sus figuras, el estudio de ablación de la recompensa, el dimensionamiento y costeo del nodo solar, y los documentos del concurso (ficha técnica, memoria de cálculo y presentación).

Referencias

- [1] P. A. Lopez, M. Behrisch, L. Bieker-Walz, J. Erdmann, Y.-P. Flötteröd, R. Hilbrich, L. Lücken, J. Rummel, P. Wagner y E. Wießner. Microscopic traffic simulation using SUMO. *21st IEEE International Conference on Intelligent Transportation Systems (ITSC)*, 2018, pp. 2575–2582.
- [2] H. Wei, N. Xu, H. Zhang, G. Zheng, X. Zang, C. Chen, W. Zhang, Y. Zhu, K. Xu y Z. Li. CoLight: Learning network-level cooperation for traffic signal control. *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)*, 2019, pp. 1913–1922.
- [3] P. Varaiya. Max pressure control of a network of signalized intersections. *Transportation Research Part C*, 36:177–195, 2013.
- [4] V. Mnih et al. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015.
- [5] M. Tan. Multi-agent reinforcement learning: Independent vs. cooperative agents. *Proceedings of the 10th International Conference on Machine Learning (ICML)*, 1993, pp. 330–337.
- [6] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus y N. Dormann. Stable-Baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268):1–8, 2021.
- [7] L. N. Alegre. SUMO-RL. Repositorio de software, 2019. <https://github.com/LucasAlegre/sumo-rl>
- [8] F. V. Webster. *Traffic Signal Settings*. Road Research Technical Paper No. 39, HMSO, Londres, 1958.
- [9] T. Kurczveil, P. A. López y E. Schnieder. Implementation of an energy model and a charging infrastructure in SUMO. En *Simulation of Urban Mobility (SUMO 2013)*, LNCS 8594, Springer, 2014.
- [10] Eclipse SUMO. Documentación: modelos de emisiones. <https://sumo.dlr.de/docs/Models/Emissions.html>
- [11] Gobierno Municipal de Puebla, Secretaría de Movilidad e Infraestructura. *Inventario de Semáforos SEMO-VINFRA (histórico)*, versiones 2020 y 2021. Portal de Datos Abiertos de Puebla Capital, Licencia Libre Uso MX. <https://datos.pueblacapital.gob.mx/dataset/inventario-de-sem%C3%A1foros>. Consultado el 26/09/2026.
- [12] Personas contribuyentes de OpenStreetMap. Datos bajo licencia ODbL. <https://www.openstreetmap.org>. Extracto descargado el 26/09/2026.
- [13] Comisión Europea, Joint Research Centre. Photovoltaic Geographical Information System (PVGIS). https://re.jrc.ec.europa.eu/pvg_tools/